

Pesquisa | LEADERS INSIGHTS REPORT

A gestão crítica de **tokens de** **IA** na empresa

O novo paradigma da eficiência computacional

A transição das corporações do uso experimental para a implementação operacional de Modelos de Linguagem de Larga Escala (LLMs) representa uma mudança sísmica na governança de TI. Neste cenário, os “tokens” emergiram como a unidade fundamental de custo, desempenho e escala na economia da IA generativa.

Gerir tokens não é mais uma tarefa puramente técnica, mas uma competência estratégica indispensável para a sustentabilidade financeira e a agilidade competitiva. O desperdício de tokens se traduz diretamente em erosão de margem e ineficiência operacional.

Este relatório sintetiza os achados de uma pesquisa realizada com **28 executivos** de médias e grandes empresas, conduzida entre 10 de junho e 10 de julho deste ano. O painel de respondentes, composto majoritariamente por C-levels e diretores de tecnologia, CX e financeiro, fornece uma visão singular sobre como as maiores organizações do país estão lidando com um tema fundamental dentro da infraestrutura de IA.

A maturidade organizacional em IA começa obrigatoriamente pelo domínio técnico dessa infraestrutura. Veja os dados a seguir.

28

AMOSTRA

executivos respondentes

30

PERÍODO (DIAS)

10 jun – 10 jul

C-level

PERFIL

e diretores de tecnologia, CX e financeiro

Maturidade técnica e as soluções adotadas

Embora quase 100% dos entrevistados afirmem que “sabem exatamente”, “conhecem o conceito por cima” ou “já ouviram falar” sobre o que seria um token, temos um cenário em que **53,6% não sabem calcular ou não entendem** o funcionamento da dinâmica de cálculo.




FAMILIARIDADE COM O CONCEITO DE “TOKEN”

- Sei exatamente o que são e como impactam os custos **46,4%**
- Conheço por cima, mas não sei calcular na prática **46,4%**
- Já ouvi falar, mas não entendo a dinâmica **7,1%**




MATURIDADE TÉCNICA

Sobre as ferramentas em uso, quase **90%** das organizações utilizam soluções prontas como ChatGPT, Copilot, Gemini e Claude. A questão permitia múltiplas respostas — e **75%** também assinalaram o uso de APIs de provedores como OpenAI, Anthropic e AWS Bedrock.



SOLUÇÕES DE IA QUE CONSOMEM TOKENS · MÚLTIPLA ESCOLHA



Nota metodológica. A pesquisa não especificou se as ferramentas comerciais eram de uso pessoal ou contratadas oficialmente pelas empresas — distinção determinante para comprovar ou afastar a hipótese do fenômeno de *Shadow AI*.

A lacuna de dados de consumo

O axioma da governança corporativa é claro: **não se gerencia o que não se mede**. Infelizmente, essa parece ser a realidade de muitas empresas quando o assunto é IA. Segundo o estudo, **46,4%** dos participantes informaram não ter acesso ao consumo mensal de tokens ou não souberam responder.

46,4%

não têm acesso ao consumo mensal de tokens ou não souberam responder.

ESTIMATIVA DE GASTO MENSAL COM CRÉDITOS / TOKENS

Não tenho acesso / prefiro não responder

46,4%

Acima de R\$ 20.000 / mês

28,6%

De R\$ 5.001 a R\$ 20.000 / mês

10,7%

De R\$ 1.001 a R\$ 5.000 / mês

7,1%

Até R\$ 1.000 / mês

7,1%

04

CONHECIMENTO DO CONSUMO

Conhecimento sobre o consumo de token

Obter precisão sobre o consumo de tokens é um dos grandes desafios de gestão para os próximos meses e anos. Segundo os dados, **75% das empresas não conhecem detalhadamente** seu consumo mensal — enquanto apenas 25% afirmam ter acesso a relatórios precisos.

25%

têm relatórios precisos e em tempo real

75%

não conhecem detalhadamente o consumo mensal de tokens



CLAREZA SOBRE TOKENS CONSUMIDOS MENSALMENTE

- Sim, apenas uma estimativa mensal consolidada **35,7%**
- Não; sabemos o custo financeiro, mas não o volume **28,6%**
- Sim, temos relatórios precisos e em tempo real **25%**
- Não fazemos ideia do volume consumido **10,7%**

O paradoxo do desperdício invisível

O desperdício de tokens é uma ineficiência técnica que drena o ROI de forma silenciosa. Loops de chamadas desnecessárias e prompts mal estruturados são responsáveis por uma parcela significativa do consumo atual.

39,3%

“INCERTEZA ANSIOSA”

dos líderes **suspeitam que estão perdendo dinheiro**, mas não possuem a instrumentação necessária para mapear o cenário real.



JÁ IDENTIFICARAM DESPERDÍCIO DE TOKENS?

	Suspeitamos que sim, mas não temos ferramentas para auditar	39,3%
	Sim, identificamos e estamos corrigindo	32,1%
	Não sabemos avaliar	28,6%


06

CUSTO CRESCENTE

O custo crescente é um desafio para escalar?

O tema está ganhando forte tração: a maior parte dos respondentes classificou o nível de preocupação como **alto**, com **39,3%** das menções no nível 4 de uma escala Likert de 1 a 5. Em segundo lugar ficou o nível 3 (moderado) e, em terceiro, o nível 5 (máximo).

NÍVEL DE PREOCUPAÇÃO COM O CUSTO CRESCENTE · ESCALA 1 A 5



Monitoramento e políticas de governança


A governança de tokens deve ser tratada como política de segurança e de alocação de recursos críticos. No entanto, a infraestrutura atual reflete um profundo “débito de governança”: 42,9% das empresas não possuem gestão centralizada e 25% não têm qualquer controle, restando apenas a expectativa sobre a fatura no fim do mês.

FERRAMENTA PARA MONITORAR O CUSTO DE TOKENS



- Não há controle centralizado **42,9%**
- Só olhamos a fatura no fim do mês **25%**
- Sim, dashboard / solução interna **17,9%**
- Sim, ferramentas de mercado **14,3%**

POLÍTICA INTERNA QUE LIMITE O USO DE TOKENS



O vetor de risco. A escassez ou ausência de controle pode explicar outro achado: 32,1% dos líderes informam que o uso de IA é totalmente livre nas empresas onde trabalham. Restam os questionamentos — representaria esse percentual o tamanho do vetor de risco para a Shadow AI e para picos orçamentários descontrolados?

Os principais números

53,6%

não sabem calcular ou entender a dinâmica de consumo de tokens.

75%

não conhecem detalhadamente o consumo mensal de tokens.

39,3%

suspeitam que perdem dinheiro, mas não conseguem auditar.

42,9%

não possuem gestão centralizada para o consumo de tokens.

32,1%

operam com uso de IA totalmente livre, sem política interna.

INOVATIVOS

LEADERS INSIGHTS REPORT